

Inteligencia Artificial

Conocimientos y razonamientos bajo incertidumbre



Parte II

Razonamiento Probabilístico

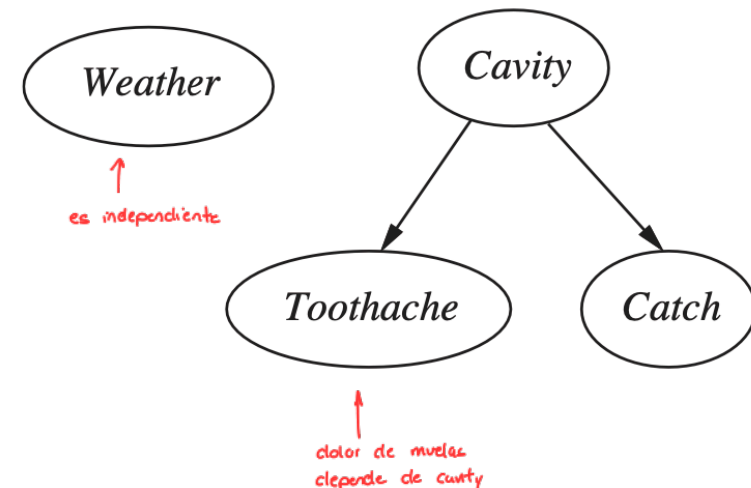
En el que explicamos cómo construir modelos de redes para razonar bajo incertidumbre de acuerdo con las leyes de la teoría de la probabilidad.

Representando incertidumbre en dominios inciertos

- La distribución de probabilidad conjunta completa puede responder a cualquier pregunta sobre el dominio, pero:
 - Puede volverse increíblemente grande a medida que aumenta el número de variables.
 - Especificar las probabilidades de los mundos posibles uno por uno es antinatural y tedioso.
- Las relaciones de independencia e independencia condicional entre variables pueden reducir en gran medida el número de probabilidades que deben especificarse para definir la distribución conjunta completa.
- Las **redes bayesianas** pueden representar esencialmente cualquier distribución de probabilidad conjunta completa de manera muy concisa.


- Grafo acíclico dirigido donde cada nodo está anotado con información de probabilidad cuantitativa
 - Cada nodo es una variable aleatoria
 - Si hay un arco de $A \rightarrow B$, A es el padre de B
 - Cada nodo X_i tiene una distribución de probabilidad condicional $P(X_i | \text{parents}(X_i))$ que cuantifica el efecto de los padres en el nodo. CPTs (Conditional Probability Table)

La probabilidad del nodo depende del padre.
y nos ahorramos saber de los "primos", "sobrinos"...



Ejemplo: Un sistema de riego

G = Hierba húmeda, S = Rociador activado, y R = Lloviendo



Conditional Probability Table (CPT)

		HIERBA HÚMEDA	
ROCIADOR	LLUVIA	T	F
F	F	0	1
F	T	0.8	0.2
T	F	0.9	0.1
T	T	0.99	0.01

Cada fila es un **caso condicional** (debe sumar 1)

Es una combinación de valores de los padres

$$P(X_1 = x_1 \wedge \dots \wedge X_n = x_n) \quad P(x_1, \dots, x_n) = \prod_{i=1}^n \theta(x_i | \text{parents}(X_i))$$

Ejemplo: SE ACOTA EL PROBLEMA:

De abajo
hacia
arriba

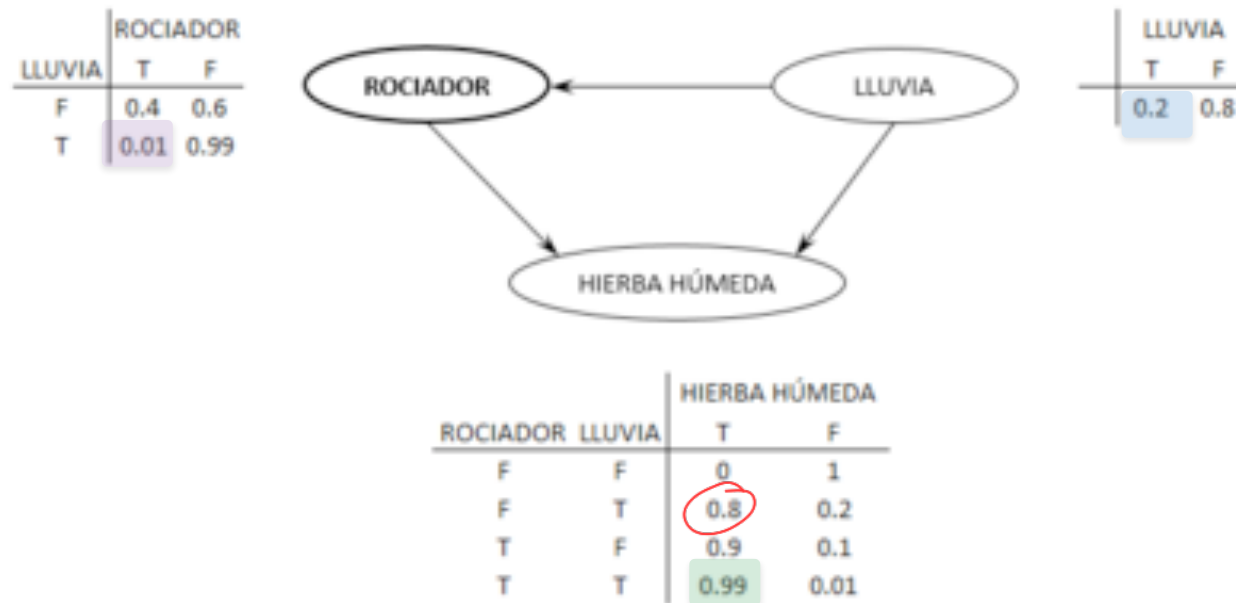
$$p(r, s, \neg g) = P(\neg g | s \wedge r)P(s | r)P(r) = 0.01 \times 0.01 \times 0.2 = 0.00002$$

$$p(r, \neg s, g) = P(g | \neg s \wedge r)P(\neg s | r)P(r) = 0.8 \times 0.99 \times 0.2 = 0.15$$

$$p(\neg r, \neg s, \neg g) = P(\neg g | \neg s \wedge \neg r)P(\neg s | \neg r)P(\neg r) = 1 \times 0.6 \times 0.8 = 0.48$$

Ejemplo: Un sistema de riego

G = Hierba húmeda, S = Rociador activado, y R = Lloviendo



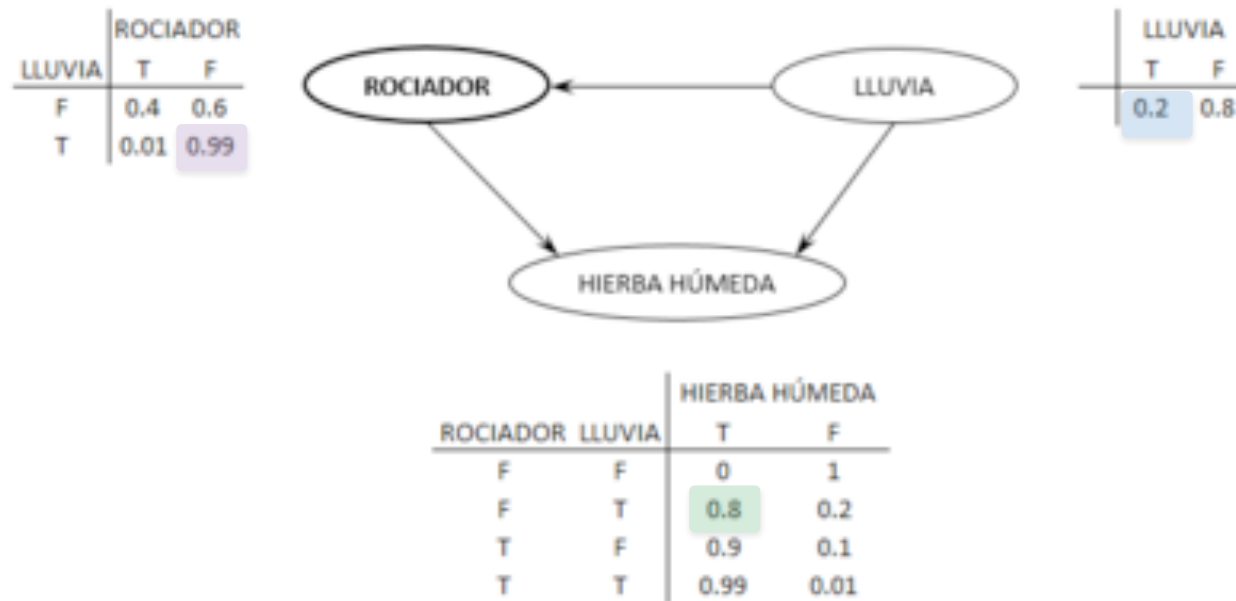
- ¿Cuál es la probabilidad de que esté lloviendo dado que la hierba está húmeda?

En forma de
redes bayesianas

$$\begin{aligned}
 P(R = T \mid G = T) &= \frac{P(G = T, R = T)}{P(G = T)} = \frac{\sum_{S \in \{T, F\}} P(G = T, S, R = T)}{\sum_{S, R \in \{T, F\}} P(G = T, S, R)} \\
 &= \frac{(0.99 \times 0.01 \times 0.2 = 0.00198_{TTT}) + (0.8 \times 0.99 \times 0.2 = 0.1584_{TFT})}{0.00198_{TTT} + 0.288_{TTF} + 0.1584_{TFT} + 0_{TFF}} \approx 35.77\%.
 \end{aligned}$$

Ejemplo: Un sistema de riego

G = Hierba húmeda, S = Rociador activado, y R = Lloviendo

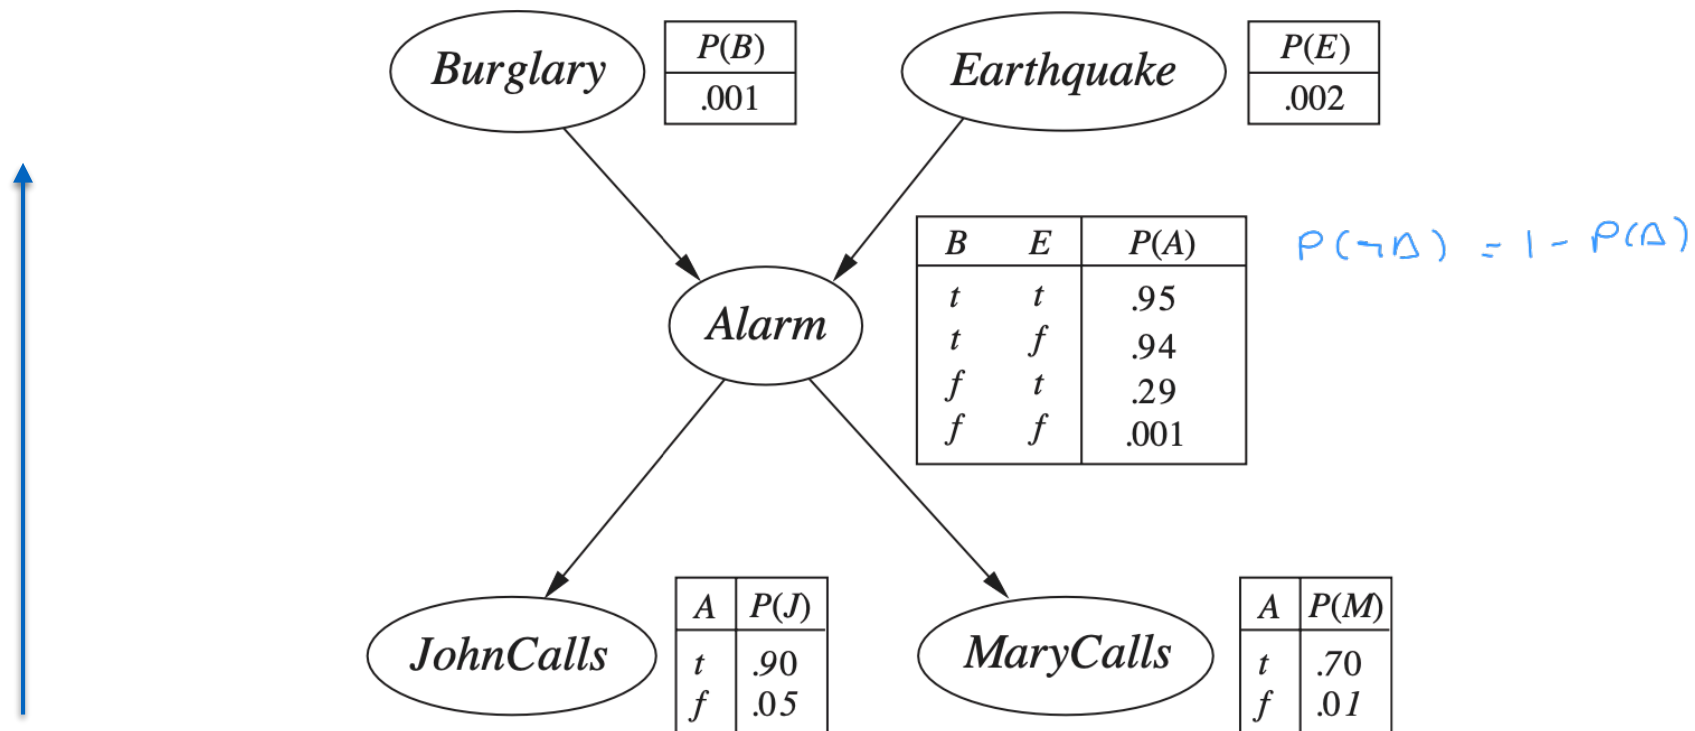


- ¿Cuál es la probabilidad de que esté lloviendo dado que la hierba está húmeda?

$$\begin{aligned}
 P(R = T \mid G = T) &= \frac{P(G = T, R = T)}{P(G = T)} = \frac{\sum_{S \in \{T, F\}} P(G = T, S, R = T)}{\sum_{S, R \in \{T, F\}} P(G = T, S, R)} \\
 &= \frac{(0.99 \times 0.01 \times 0.2 = 0.00198_{TTT}) + (0.8 \times 0.99 \times 0.2 = 0.1584_{TFT})}{0.00198_{TTT} + 0.288_{TTF} + 0.1584_{TFT} + 0_{TFF}} \approx 35.77\%.
 \end{aligned}$$

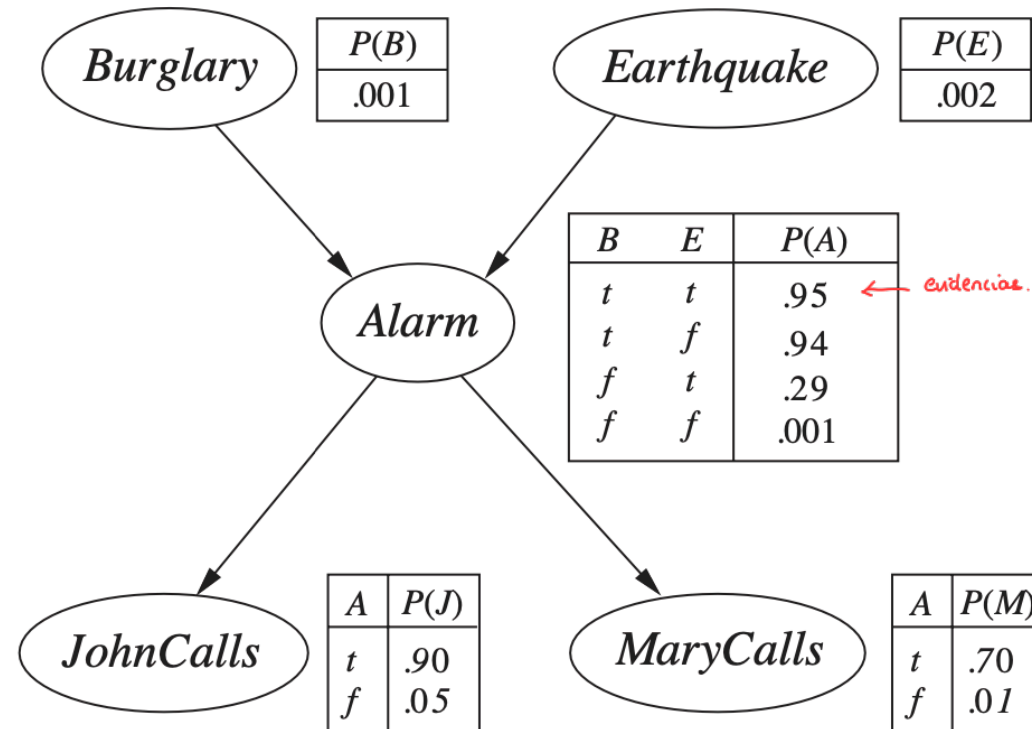
Ejemplo: Un sistema de alarma

Red Bayesiana típica, mostrando la topología y las Tablas de Probabilidad Condicional (TPC).



$$\begin{aligned}
 P(j, m, a, \neg b, \neg e) &= P(j | a)P(m | a)P(a | \neg b \wedge \neg e)P(\neg b)P(\neg e) \\
 &= 0.90 \times 0.70 \times 0.001 \times 0.999 \times 0.998 = 0.000628
 \end{aligned}$$

Ejemplo: Un sistema de alarma



- ¿Cuál es la probabilidad de que John llame? $P(j|a) + P(j|\neg a)$
- ¿Cuál es la probabilidad de que la alarma suene y Mary y John llamen sin que haya habido un robo o un terremoto?
 $P(a, m, j, \neg r, \neg e)$

Método para construir de Redes Bayesianas

1. Reescribe las entradas en la distribución conjunta en términos de probabilidad condicional, usando la **regla del producto**

$$P(x_1, \dots, x_n) = P(x_n | x_{n-1}, \dots, x_1) P(x_{n-1}, \dots, x_1)$$

2. Repite el proceso, reduciendo cada probabilidad conjuntiva a una probabilidad condicional y una conjunción más pequeña

$$\begin{aligned} P(x_1, \dots, x_n) &= P(x_n | x_{n-1}, \dots, x_1) P(x_{n-1} | x_{n-2}, \dots, x_1) \cdots P(x_2 | x_1) P(x_1) \\ &= \prod_{i=1}^n P(x_i | x_{i-1}, \dots, x_1) . \end{aligned}$$

Regla de la Cadena

La prob. de cada nodo depende de la probabilidad de los padres.

$$\mathbf{P}(X_i | X_{i-1}, \dots, X_1) = \mathbf{P}(X_i | \text{Parents}(X_i))$$

La red bayesiana es una representación correcta del dominio solo si cada nodo es condicionalmente independiente de sus otros predecesores en el orden de los nodos, dados sus padres

• Metodología para cumplirlo

1. **Nodos:** Determina las variables requeridas y ordénalas de tal manera que las causas preceden a los efectos $\{X_1, \dots, X_n\}$
2. **Arcos.** for $i=0$ to n : (cuando identificamos los padres)
 - a. Elige de X_1, \dots, X_{i-1} el conjunto mínimo de padres que realmente tengan una influencia directa
 - b. Haz un arco de cada padre a X_i
 - c. **CPTs:** Haz la tabla $\mathbf{P}(X_i | \text{Parents}(X_i))$

$$\mathbf{P}(\text{MaryCalls} | \text{JohnCalls}, \text{Alarm}, \text{Earthquake}, \text{Burglary}) = \mathbf{P}(\text{MaryCalls} | \text{Alarm})$$





FIGURE 3.11 A Bayesian network representing the distribution

$$P(x_6 \mid x_5)P(x_5 \mid x_2, x_3)P(x_4 \mid x_1, x_2)P(x_3 \mid x_1)P(x_2 \mid x_1)P(x_1)$$

$$\begin{aligned} P(x_1, x_2, x_3, x_4, x_5, x_6) \\ = P(x_6 \mid x_5)P(x_5 \mid x_2, x_3)P(x_4 \mid x_1, x_2) \cdot P(x_3 \mid x_1)P(x_2 \mid x_1)P(x_1) . \end{aligned}$$


Judea Pearl, Probabilistic Reasoning in Intelligent Systems Published by Morgan Kaufmann

Relaciones condicionales de independencia

Markov blanket

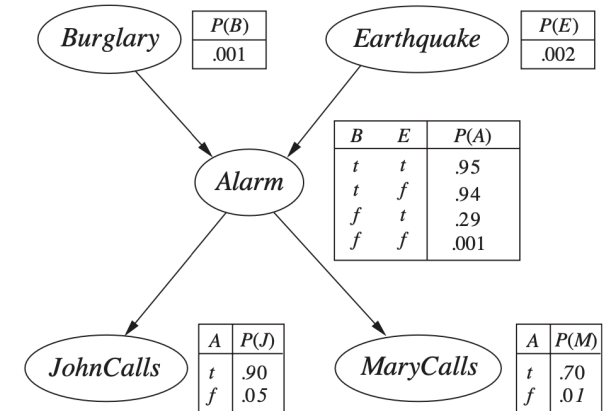
Un nodo X es condicionalmente independiente de sus no descendientes (los Z_{is}) dados sus padres (los U_i mostrados en el área gris).

JohnCalls es independiente de *Burglary*, *EarthQuake* y *MaryCalls* dado el valor de *Alarm*.



Un nodo X está relacionado con los nodos dentro de su **manto de Markov** (el área gris).

Burglary es independiente de *JohnCalls*, y *MaryCalls* dado el valor de *Alarm* y *EarthQuake*.



Inferencia Exacta en Redes Bayesianas

- La **tarea básica** de cualquier sistema de inferencia probabilístico es **calcular la distribución de probabilidad posterior para un conjunto de variables de consulta**, dado algún **evento observado**, es decir, **alguna asignación de valores a un conjunto de variables de evidencia**.

↑
evidencia

- Notación

- X es la variable de consulta
- \mathbf{E} es el conjunto de variables de evidencias E_1, \dots, E_m y \mathbf{e} es un evento particular observado
- \mathbf{Y} es el conjunto de variables de no evidencias, ni de consulta Y_1, \dots, Y_l (**variables ocultas**)
- La consulta es $\mathbf{P}(X | \mathbf{e})$

$$\mathbf{X} = \{X\} \cup \mathbf{E} \cup \mathbf{Y}$$

↑ preguntamos algo en base a las evidencias.

$$\mathbf{P}(\text{Burglary} | \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true}) = \langle 0.284, 0.716 \rangle$$

Inferencia por enumeración

- Como vimos en la Parte I *normalización*.

$$P(B|j, m) = \alpha P(B, j, m) = \alpha \sum_e \sum_a P(B, j, m, e, a)$$
no tiene nada asignado.
variable aleatoria (todos los posibles casos).
- Usando Redes Bayesianas, en función de las CPTs

$$P(b|j, m) = \alpha \sum_e \sum_a P(b)p(e)P(a|b, e)P(j|a)P(m|a)$$
los posibles casos


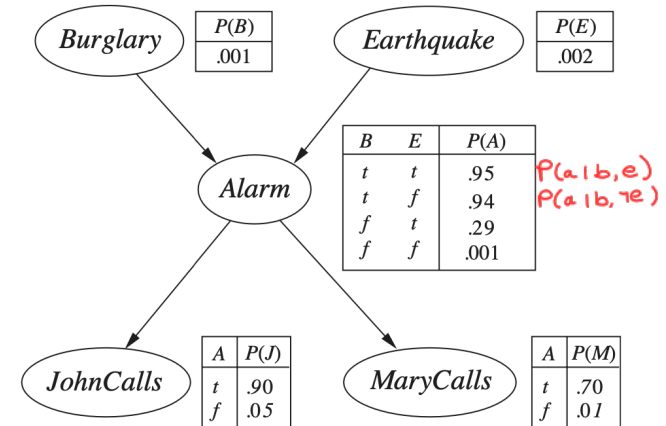
$$P(b|j, m) = \alpha P(b) \sum_e p(e) \sum_a P(a|b, e)P(j|a)P(m|a)$$
si o no la alarma

$$P(b|j, m) = \alpha \times 0.00059224$$

$$P(B|j, m) = \alpha \langle 0.00059224, 0.0014919 \rangle \approx \langle 0.284, 0.716 \rangle$$
distribución de las probabilidades.

La posibilidad de un robo, dadas las llamadas de ambos vecinos, es de alrededor del 28%.

$O(n2^n)$



function ENUMERATE-ASK(X, e, bn) **returns** a distribution over X
inputs: X , the query variable

e , observed values for some set of variables E
 bn , a Bayes net

$Q \leftarrow$ a distribution over X , where $Q(x_i)$ is $P(X=x_i)$

for each value x_i that X can have **do**

$Q(x_i) \leftarrow$ ENUMERATE-ALL($bn.VARS, e, x_i$), where e, x_i is the evidence e plus the assignment $X=x_i$

return NORMALIZE(Q)

function ENUMERATE-ALL($vars, e$) **returns** a probability (a real number in $[0,1]$)
inputs: $vars$, a list of all the variables

e , observed values for some set of variables E

if EMPTY($vars$) **then return** 1.0

$Y \leftarrow$ FIRST($vars$)

if Y is assigned a value (call it y) in e **then**

return $P(Y=y | \text{values assigned to } Y\text{'s parents in } e) \times$ ENUMERATE-ALL($REST(vars), e$)

else

return $\sum_{y_i} [P(Y=y_i | \text{values assigned to } Y\text{'s parents in } e) \times$ ENUMERATE-ALL($REST(vars), e, y_i$)],

where e, y_i is the evidence e plus the assignment $Y=y_i$

B no está asignado.
si no está asignado, hay que iterar.


<http://courses.csail.mit.edu/6.034s/handouts/spring12/bayesnets-pseudocode.pdf>

Caso base (⊕) recursividad. (↑)

El algoritmo de eliminación de variables

- La idea es simple: **hacer el cálculo una vez y guardar los resultados para su uso posterior**
- La eliminación de variables funciona:
 - Evaluando expresiones de derecha a izquierda, o en la la figura de abajo hacia arriba

$$P(b|j,m) = \alpha P(b) \sum_e p(e) \sum_a P(a|b,e) P(j|a) P(m|a)$$



- Los resultados intermedios se almacenan y las sumas de cada variable se realizan solo para aquellas partes de la expresión que dependen de la variable.

$$P(B|j,m) = \alpha \underbrace{P(B)}_{f_1(B)} \sum_e \underbrace{P(e)}_{f_2(E)} \sum_a \underbrace{P(a|B,e)}_{f_3(A,B,E)} \underbrace{P(j|a)}_{f_4(A)} \underbrace{P(m|a)}_{f_5(A)}$$

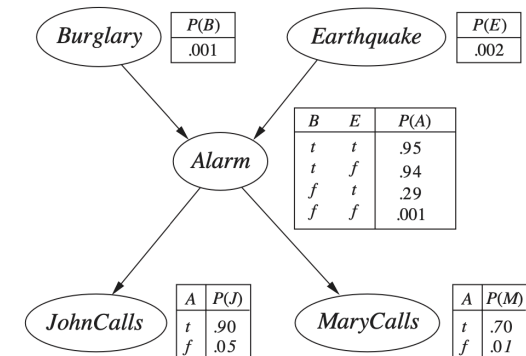
$$P(B|j,m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A,B,E) \times f_4(A) \times f_5(A)$$

$$f_4(A) = \begin{pmatrix} P(j|a) \\ P(j|\neg a) \end{pmatrix} = \begin{pmatrix} 0.90 \\ 0.05 \end{pmatrix}$$

$$f_5(A) = \begin{pmatrix} P(m|a) \\ P(m|\neg a) \end{pmatrix} = \begin{pmatrix} 0.70 \\ 0.01 \end{pmatrix}$$

$f_3(A, B, E)$ es una matriz de $2 \times 2 \times 2$ $P(a|b,e) = 0.95 \rightarrow P(\neg a|\neg b, \neg e) = 0.999$

cada **factor** es una **matriz indexada por los valores de sus variables de argumento**



$$P(B | j, m) = \alpha f_1(B) \times \sum_e f_2(E) \times \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A)$$

- \times es una operación llamada **pointwise product**:
 - El pointwise product de dos factores f_1 y f_2 produce un nuevo factor f cuyas variables **son la unión** de las variables en f_1 y f_2 y cuyos elementos están dados por el producto de los elementos correspondientes en los dos factores.

$$f_1(A, B) \times f_2(B, C) = f_3(A, B, C).$$

A	B	$f_1(A, B)$	B	C	$f_2(B, C)$	A	B	C	$f_3(A, B, C)$
T	T	.3	T	T	.2	T	T	T	$.3 \times .2 = .06$
T	F	.7	T	F	.8	T	T	F	$.3 \times .8 = .24$
F	T	.9	F	T	.6	T	F	T	$.7 \times .6 = .42$
F	F	.1	F	F	.4	T	F	F	$.7 \times .4 = .28$
						F	T	T	$.9 \times .2 = .18$
						F	T	F	$.9 \times .8 = .72$
						F	F	T	$.1 \times .6 = .06$
						F	F	F	$.1 \times .4 = .04$

$$P(B | j, m) = \alpha \overset{2 \times 1}{f_1(B)} \times \overset{2 \times 1}{\sum_e f_2(E)} \times \overset{2 \times 2 \times 2}{\sum_a f_3(A, B, E)} \times \overset{2 \times 1}{f_4(A)} \times \overset{2 \times 1}{f_5(A)}$$

- El proceso de evaluación es un proceso de **sumar variables (de derecha a izquierda)** a partir de productos puntuales de factores para producir nuevos factores, lo que finalmente produce un factor que es la solución, es decir, la distribución posterior sobre la variable de consulta:

1. Primero, sumamos A del producto de f3, f4 y f5 para obtener un nuevo factor f6(B|E)

$$\begin{aligned} f_6(B, E) &= \sum_a f_3(A, B, E) \times f_4(A) \times f_5(A) \\ &= (\underset{2 \times 2}{f_3(a, B, E)} \times \underset{1}{f_4(a)} \times \underset{1}{f_5(a)}) + (\underset{2 \times 2}{f_3(\neg a, B, E)} \times \underset{1}{f_4(\neg a)} \times \underset{1}{f_5(\neg a)}) \end{aligned}$$

eliminamos variables

$$P(B | j, m) = \alpha \overset{2 \times 1}{f_1(B)} \times \overset{2 \times 1}{\sum_e f_2(E)} \times \overset{2 \times 2}{f_6(B, E)}$$

2. A continuación, sumamos E del producto de f2 y f6

$$\begin{aligned} f_7(B) &= \sum_e \overset{2 \times 1}{f_2(E)} \times \overset{2 \times 2}{f_6(B, E)} \\ &= \underset{1}{f_2(e)} \times \underset{2 \times 1}{f_6(B, e)} + \underset{1}{f_2(\neg e)} \times \underset{2 \times 1}{f_6(B, \neg e)} \end{aligned}$$

$$P(B | j, m) = \alpha \overset{2 \times 1}{f_1(B)} \times \overset{2 \times 1}{f_7(B)}$$

que se puede evaluar tomando el pointwise product y normalizando el resultado.

Algoritmo de derecha a izquierda.

$$\mathbf{P}(B \mid j, m) = \alpha \mathbf{f}_1(B) \times \sum_e \mathbf{f}_2(E) \times \sum_a \mathbf{f}_3(A, B, E) \times \mathbf{f}_4(A) \times \mathbf{f}_5(A)$$

function ELIMINATION-ASK(X, \mathbf{e}, bn) **returns** a distribution over X

inputs: X , the query variable

\mathbf{e} , observed values for variables \mathbf{E}

bn , a Bayesian network specifying joint distribution $\mathbf{P}(X_1, \dots, X_n)$

$factors \leftarrow []$

for each var **in** ORDER($bn.VARS$) **do**

$factors \leftarrow [\text{MAKE-FACTOR}(var, \mathbf{e}) | factors]$

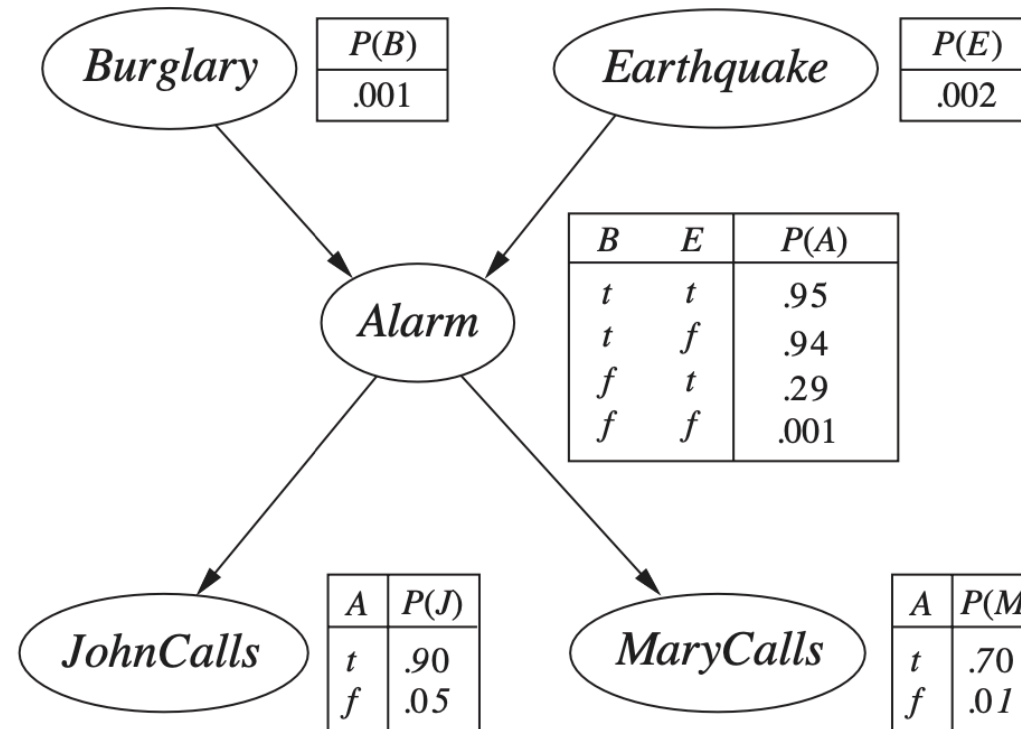
if var **is a hidden variable** **then** $factors \leftarrow \text{SUM-OUT}(var, factors)$

return NORMALIZE(POINTWISE-PRODUCT($factors$))

↑ definir una lista ...

$$\mathbf{P}(B \mid j, m) = \alpha \mathbf{f}_1(B) \times \mathbf{f}_7(B)$$

Ejercicio: Un sistema de alarma



- ¿Cuál es la probabilidad de que haya un ladrón dado que John y Mary llaman?

Referencias

Capítulo 13. Russell S., Norving P. “Artificial intelligence, A Modern Approach”. 2022, Pearson.

https://es.wikipedia.org/wiki/Red_bayesiana

<https://www.youtube.com/watch?v=hEZjPZ-Ze0A>

<http://courses.csail.mit.edu/6.034s/handouts/spring12/bayesnets-pseudocode.pdf>